Sommaire

Résumé 5
Abstract 6
Chapitre 1 : État de l'Art 9
I. Concept Clés du Domaine d'Application 10
1. Télémédecine et Santé Connectée 10
2. Éducation et Prévention Médicale : 11
II. Concepts Clés du Sujet 11
1. Traitement du Langage Naturel 12
2. Les architectures des models du langage large 16
3. Le Fine-tuning : 18
3.1. Fonctionnement du fine-tuning : 18
3.2. Importance du Fine-tuning : 19
3.3. Les méthodes du fine-tuning 19
4. Retrieval-Augmented Generation 20
5. Base de données vectorielle 21
6. La différence entre RAG et Fine-Tuning 21
7. Agent Conversationnel (Chatbot) 22
Conclusion 23
Chapitre 2 : Travaux Connexes 25
I. Les modèles prés entrainés 26
II. Les modèles prés entrainés dans la biomédecine 27
III. Avantages et Limites des Méthodes Existantes : 28
IV. Exemple d'application 29
V. Choix de l'Approche et Valeur Ajoutée 29
Conclusion : 30
Chapitre 3 : Description du projet 31
I. Workflow du projet 32
1. Créer des morceaux(chunks) 33
2. Générer des intégrations (embeddings) 35

3. Stocker les embeddings dans une base de données vectorielle 36
4. Interface utilisateur 36
5. Intégrer la requête 36
6. Récupérer des morceaux similaires 37
II. Les modèles utilisés 38
Conclusion : 39
Chapitre 4 : Réalisation et évaluation 40
I. Métriques de performance 41
II. Visualisation des résultats 42
III. Evaluation des performances 44
IV. Déploiement de solution proposée 46
Conclusion 48
Conclusion générale et Perspectives 49
Bibliography 50

Liste des Tableaux

Table 1: Différence entre RAG et Fine-tuning 21
Table 2 : Types de chatbot 23
Table 3 : modèles decoder 27
Table 4: Les modèles existants 28
Table 5: Les performances des modèles du chapitre état de l'art 45
Table 6: Les métriques du RAG 45
Table 7: Comparaison entre les modèles existants et le système RAG 46

Liste des Figures

Figure 1:Traitement du NLP 12
Figure 2: Exemple du Bag of Words [2] 13
Figure 3: Exemple TF-IDF [4] 13
Figure 4: Word2Vec [6] 14
Figure 5: POS tagging [9] 14
Figure 6: Natural Language Understanding [12] 15
Figure 7: BERT Architecture [15] 16
Figure 8: GPT Architecture 17
Figure 9: Encoder-Decoder Architecture [18] 17
Figure 10: Traitement du Fine-tuning [19] 18
Figure 11: Fine-Tune LLMs [21] 19
Figure 14: Prompt Tuning [26] 20
Figure 23: Architecture Système 32
Figure 24: Découpage en morceaux de taille fixe avec chevauchement. [44] 33
Figure 25: Découpage sémantique basé sur la similarité cosinus. 33
Figure 26: Segmentation récursive avec découpage en sous-blocs. 34
Figure 27: Morceautage basé sur la structure du document. 35
Figure 28: Génération des embeddings à partir des chunks. 35
Figure 29: Stockage des embeddings dans une base de données vectorielle. 36
Figure 31: Conversion de la requête utilisateur en embedding vectoriel. 37
Figure 32: Recherche des vecteurs similaires dans la base de données vectorielle. 37
Figure 33: Morceaux similaires récupérés pour la requête. 37
Figure 36: similarité score pour le modèle microsoft/BioGPT 42
Figure 37: Courbe de F1-Scores 43
Figure 38: Prompt 44
Figure 39: Réponse avant RAG Figure 40: Réponse après RAG 44
Figure 41: Capture d'écran de l'interface utilisateur du chatbot 47

Résumé

Ce projet vise à développer un chatbot médical intelligent capable d'analyser les symptômes exprimés en langage naturel par les utilisateurs et de fournir des réponses médicales contextualisées. Pour cela, le système s'appuie sur un modèle de langage pré entraîné, enrichi par une base de connaissances médicale indexée dans une base vectorielle via l'approche Retrieval-Augmented Generation. L'objectif principal est de proposer une assistance médicale automatisée de premier niveau, permettant une évaluation rapide des symptômes, une orientation vers les bonnes spécialités et une sensibilisation aux pathologies. Le système utilise notamment ChromaDB pour la recherche de documents pertinents et le modèle llm pour la génération des réponses. Ce projet contribue à rendre l'accès à l'information médicale plus rapide, fiable et accessible, tout en soutenant les professionnels de santé dans leur pratique.

Abstract

This project aims to develop an intelligent medical chatbot capable of analyzing user-described symptoms written in natural language and providing context-aware medical responses. The system is built on a pretrained language model, enhanced by a medical knowledge base indexed in a vector database using the Retrieval-Augmented Generation (RAG) approach. The main objective is to offer automated first-level medical support that enables quick symptom assessment, guidance to the appropriate medical specialties, and user education about possible conditions. The system leverages ChromaDB for document retrieval and llm model for generating accurate responses. Overall, this project helps improve access to reliable medical information while supporting healthcare professionals in their diagnostic process.

Introduction Générale

L’identification précoce des maladies représente un enjeu fondamental pour les systèmes de santé modernes. Elle permet non seulement d’améliorer considérablement le pronostic des patients, mais aussi de limiter la progression des affections, de réduire les coûts liés aux soins à long terme, et d’optimiser l'utilisation des ressources médicales. Détecter rapidement les symptômes et poser un diagnostic précis est ainsi une étape essentielle pour garantir une prise en charge efficace et adaptée.

Cependant, ce processus demeure complexe et semé d’obstacles. La diversité des pathologies, la similitude entre les signes cliniques de différentes maladies, ainsi que la nature souvent subjective des symptômes exprimés par les patients rendent l’analyse médicale particulièrement délicate. Même les professionnels de santé expérimentés peuvent se heurter à des difficultés d’interprétation, notamment lorsque les signes sont atypiques, discrets ou non spécifiques.

Par ailleurs, plusieurs facteurs systémiques contribuent à aggraver ces défis. Les structures hospitalières sont souvent surchargées, en particulier dans les zones à forte densité de population. Le manque de médecins généralistes ou spécialistes dans certaines régions, notamment rurales ou défavorisées, limite l'accès rapide à un diagnostic médical. Dans certains pays en développement, l'insuffisance des infrastructures médicales et la disparité dans la répartition des professionnels de santé accentuent les inégalités en matière de soins.

Dans ce contexte, le recours aux technologies numériques et à l’intelligence artificielle dans le domaine médical suscite un intérêt croissant. L’essor des modèles d’apprentissage automatique et des grands modèles de langage permet aujourd’hui de concevoir des systèmes capables de comprendre et d’interpréter des descriptions de symptômes formulées en langage naturel. Ces outils peuvent assister le corps médical en fournissant un premier niveau d’évaluation, en suggérant des pistes diagnostiques, ou en orientant les patients vers des soins appropriés.

En particulier, les assistants conversationnels intelligents, intégrant des modèles d’IA spécialisés et des bases de connaissances médicales, représentent une avancée prometteuse. Ils peuvent être déployés dans des applications de triage, de prévention, ou encore de soutien psychologique. Dans des contextes où l’accès aux soins est limité, ces systèmes peuvent faire office d’interface initiale entre le patient et le système de santé, en assurant une pré-évaluation fiable et rapide.

Ainsi, la mise en œuvre d'un système intelligent d'analyse des symptômes, basé sur l'extraction de connaissances médicales et l'interaction en langage naturel, peut contribuer à améliorer l'efficacité du diagnostic précoce, renforcer la qualité des soins, et favoriser une médecine plus accessible et proactive.

C'est dans cette perspective que s'inscrit le présent projet, qui vise à concevoir un chatbot médical intelligent capable d'analyser les symptômes décrits par l'utilisateur et de fournir des réponses claires, pertinentes et contextualisées. Pour cela, nous nous appuyons sur l'approche Retrieval-Augmented Generation, qui permet de combiner les capacités linguistiques d'un modèle de langage pré-entraîné avec une base de données médicale structurée et indexée via ChromaDB.

Ce rapport est structuré en plusieurs chapitres. Le premier chapitre présente l'état de l'art, en abordant les notions clés du domaine médical, les fondements de l'intelligence artificielle appliquée à la santé. Le deuxième chapitre présente un aperçu des travaux connexes ainsi que les avantages et les limites des modèles existants et le choix de la valeur ajoutée. Le troisième chapitre détaille la solution adoptée, notamment l'architecture du système et le choix des modèles. Le quatrième chapitre est dédié à l'évaluation des performances du système à travers différentes métriques, la visualisation des performances et le déploiement de la solution proposé. Enfin, la conclusion générale et les perspectives d'évolution du projet.

Chapitre 1 : État de l’Art

Dans ce chapitre, je vais explorer les différents aspects liés à l'analyse des symptômes pour la détection des maladies. Je commencerai par définir les concepts clés du domaine médical, avant de présenter les principes fondamentaux de l'intelligence artificielle pour ce sujet. Ensuite, je ferai une revue sur les travaux existants. Enfin, je détaillerai le choix de l'approche retenue ainsi que sa valeur ajoutée.

I. Concept Clés du Domaine d'Application

Le projet s'intègre dans le domaine en pleine évolution de la santé numérique, qui vise à repenser l'organisation des soins grâce à l'usage des technologies modernes. La prévalence croissante des maladies et la pression exercée sur les structures médicales, les outils numériques apparaissent comme une réponse stratégique. Ils permettent notamment d'améliorer l'efficacité des soins, de faciliter l'accès aux services de santé, et d'optimiser la qualité du suivi des patients.

1. Télémédecine et Santé Connectée

La télémédecine et la santé connectée jouent un rôle central dans l'amélioration de l'accès aux soins et l'optimisation des processus médicaux à distance. Ces deux domaines sont étroitement liés à l'évolution des pratiques médicales modernes et permettent une meilleure gestion des parcours de soins, notamment en facilitant la première évaluation des symptômes, l'orientation vers les bonnes spécialités, et l'optimisation des téléconsultations. Ils s'articulent notamment autour deux axes complémentaires, la première évaluation des symptômes et l'orientation vers les spécialistes.

- **Première Évaluation des Symptômes :**

Dans un contexte où les structures de santé sont parfois surchargées, l'idée de permettre une première analyse des symptômes à distance devient essentielle. Cela permet de filtrer efficacement les cas urgents et d'orienter rapidement les patients vers les bons interlocuteurs. De plus, cette évaluation s'inscrit parfaitement dans un système de santé connecté, où les objets médicaux connectés viennent enrichir le suivi des patients.

- **Orientation Vers les Spécialistes :**

L'orientation du patient vers le spécialiste approprié représente un défi majeur, mais avec l'intégration de solutions de télémédecine et de l'intelligence artificielle, il devient possible

d'améliorer cette étape. Grâce à l'analyse des symptômes collectés à distance, les patients peuvent être dirigés vers les bons professionnels, réduisant ainsi les délais d'attente et évitant les consultations inutiles.

2. Éducation et Prévention Médicale :

L'éducation et la prévention sont des éléments clés pour limiter les risques de maladies et améliorer la santé publique. Ces stratégies s'inscrivent en complément des outils de télémédecine, en aidant à sensibiliser la population aux comportements à adopter pour prévenir certaines pathologies. Ils s'articulent notamment autour deux axes complémentaires, la sensibilisation aux pathologies et la promotion d'une hygiène de vie saine.

- **Sensibilisation aux pathologies :**

Informer les citoyens sur les pathologies et les comportements à adopter est essentiel pour la prévention. Cela peut être facilité par des outils numériques qui, en combinaison avec l'intelligence artificielle, permettent de fournir des informations médicales adaptées et personnalisées.

- **Promotion d'une Hygiène de Vie Saine :**

L'intelligence artificielle et la télémédecine peuvent également jouer un rôle dans la promotion d'une hygiène de vie saine, en fournissant des recommandations adaptées à chaque individu en fonction de ses antécédents et de ses données médicales collectées. Ces conseils sur mesure contribuent à la prévention des maladies chroniques et des affections liées au mode de vie.

II. Concepts Clés du Sujet

Dans un premier temps, nous aborderons le Traitement du Langage Naturel, qui constitue le cœur du dialogue entre l'utilisateur et le système. Nous détaillerons son fonctionnement. Ensuite, les architectures des modèles de langage sont explorées (Encoder, Decoder, Encoder-Decoder), suivies par une explication du fine-tuning, sa logique, ses apports et les principales méthodes utilisées.

Nous abordons également l'approche Retrieval-Augmented Generation, qui permet d'enrichir les réponses générées à partir de documents externes, ainsi que la notion de base de données vectorielle, essentielle pour la mise en œuvre de cette stratégie.

Une comparaison entre le RAG et le Fine-Tuning est ensuite proposée pour mieux comprendre leurs rôles respectifs. Le chapitre se conclut par une présentation du chatbot médical, principal canal d'interaction entre l'utilisateur et le système.

1. Traitement du Langage Naturel

Le Traitement du Langage Naturel est un sous-domaine de l'intelligence artificielle qui permet aux machines de comprendre et d'interagir avec le langage utilisé par les humains. Il englobe un ensemble de techniques permettant d'analyser, de structurer, et d'interpréter automatiquement des textes ou des paroles en langage courant. En s'appuyant sur des approches linguistiques et des modèles d'apprentissage, il rend possible l'extraction d'informations utiles à partir de données textuelles. Dans le domaine médical, il est utile pour traiter des descriptions de symptômes.

Le NLP permet de comprendre, interpréter et produire du langage humain. Il s'appuie sur différentes techniques issues de l'informatique, de la linguistique et de l'intelligence artificielle. La figure 1présente les étapes clés du traitement du NLP.



Figure 1:Traitement du NLP

a. Prétraitement du texte :

Avant toute phase d'analyse, il est nécessaire de préparer le texte brut afin de le rendre exploitable par les algorithmes. Cette étape débute par la tokenisation, qui consiste à segmenter le texte en unités élémentaires telles que les mots ou les phrases. Ensuite, une normalisation est appliquée, notamment en convertissant tous les caractères en minuscules pour assurer l'uniformité.

Des mots considérés comme peu informatifs, appelés mots vides (par exemple : « le », « est », « de »), sont ensuite supprimés pour ne conserver que les termes porteurs de sens. Vient ensuite la lemmatisation ou la racinisation, qui vise à ramener chaque mot à sa forme canonique ou racine (par exemple, « marchaient » devient « marcher »). Enfin, un nettoyage final permet de retirer la ponctuation, les caractères spéciaux et parfois les chiffres, dans le but de limiter les biais et de faciliter le traitement automatique du contenu textuel.

b. Extraction de caractéristiques :

Une fois le texte prétraité, il devient nécessaire de le convertir en une représentation numérique que les algorithmes d'apprentissage automatique ou les modèles de langage peuvent traiter. Cette étape, appelée extraction de caractéristiques, consiste à transformer le langage naturel en vecteurs numériques qui reflètent, autant que possible, le sens et la structure du texte.

- **Représentations classiques : Bag of Word et TF-IDF**

Les méthodes traditionnelles, telles que le Bag of Words (BoW) [1], consistent à représenter chaque document par un vecteur indiquant la fréquence de chaque mot dans le texte. Cette approche, bien que simple, ignore l'ordre des mots et le contexte sémantique. Elle reste toutefois efficace pour des tâches comme la classification de textes ou l'analyse de sentiment, lorsqu'un vocabulaire limité suffit. La figure 2 présente un exemple du Bag of Words

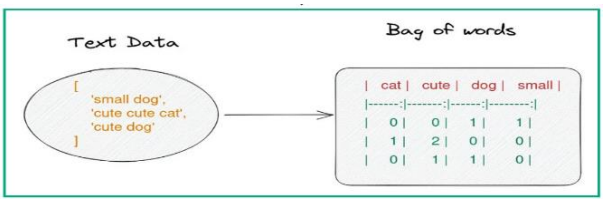


Figure 2: Exemple du Bag of Words [2]

Une version plus raffinée de cette méthode est le TF-IDF (Term Frequency – Inverse Document Frequency) [3]. Cette technique pondère la fréquence d'un mot dans un document en tenant compte de sa rareté dans l'ensemble du corpus. Ainsi, les mots très fréquents mais peu discriminants (comme "patient", "maladie") reçoivent un poids moindre, tandis que les termes plus spécifiques (ex. : "bronchopneumonie") ont une influence accrue sur la représentation du texte. La figure 3 présente un exemple du TF-IDF

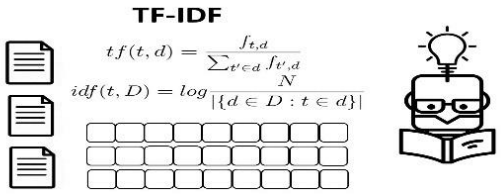


Figure 3: Exemple TF-IDF [4]

- **Plongements lexicaux contextuels : Word2Vec, GloVe**

Les méthodes statistiques classiques présentent des limites : elles ne tiennent pas compte de la signification contextuelle des mots. Pour pallier cela, des techniques plus avancées comme Word2Vec, GloVe (Global Vectors for Word Representation) ou FastText ont été développées. Ces modèles de plongement lexical (word embeddings) projettent chaque mot dans un espace vectoriel dense, où les distances entre vecteurs reflètent les similarités sémantiques. Par

exemple, les mots "médecin" et "chirurgien" auront des représentations proches, car ils apparaissent dans des contextes similaires. Cela permet au système de capturer des relations lexicales et conceptuelles plus fines qu'avec BoW ou TF-IDF.

Word2Vec [5] apprend ces vecteurs en prédisant un mot à partir de son contexte (ou inversement), via des réseaux de neurones simples. La figure 4 présente un exemple de Word2Vec.

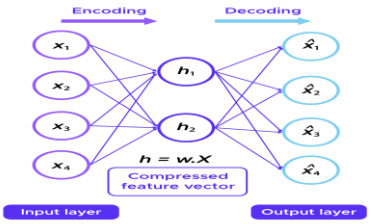


Figure 4: Word2Vec [6]

GloVe [6], de son côté, utilise des statistiques globales de cooccurrence de mots pour produire des vecteurs interprétables et cohérents.

c. Analyse du texte :

Une fois le texte prétraité et transformé en représentation exploitable, l'étape suivante consiste à en extraire du sens et des informations structurées. Cette analyse peut prendre plusieurs formes complémentaires selon les objectifs visés :

- **Analyse morphosyntaxique :**

Cette technique permet d'identifier la nature grammaticale de chaque mot, aussi appelée part-of-speech tagging (POS tagging) [7]. On détermine ainsi si un mot est un nom, un verbe, un adjectif, etc., ce qui est essentiel pour comprendre la structure des phrases et en faciliter l'interprétation automatique. La figure 5 présente un exemple du POS tagging.

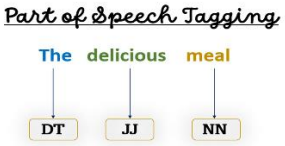


Figure 5: POS tagging [9]

- **Reconnaissance des entités nommées (NER) :**

La Named Entity Recognition [8] vise à repérer dans un texte des entités spécifiques comme des noms de personnes, lieux, organisations, dates ou unités médicales (ex. : "aspirine", "Dr

Dupont", "3 mars 2021"). Cette étape est particulièrement utile dans le domaine médical pour extraire des éléments cliniques clés des rapports ou des dialogues patients.

- **Analyse de dépendance syntaxique :**

Grâce à des graphes de dépendances, cette méthode permet de comprendre les relations grammaticales entre les mots d'une phrase (sujet-verbe, complément, etc.). Cela offre une compréhension plus fine de la structure linguistique et aide à interpréter correctement les intentions de l'utilisateur.

- **Analyse des sentiments :**

Cette technique évalue le ton émotionnel du texte, en classant les phrases selon qu'elles expriment une opinion positive, négative ou neutre. Bien que couramment utilisée en marketing, elle peut aussi être utile en santé pour détecter la détresse ou la satisfaction d'un patient.

- **Compréhension du langage naturel (NLU) :**

Le Natural Language Understanding [9] est une sous-branche du NLP qui vise à interpréter le sens global d'une phrase, même lorsqu'elle est formulée de manière ambiguë ou implicite. Cela inclut des tâches comme l'identification de l'intention, la résolution de coréférence (ex. : "le patient a pris son traitement. Il se sent mieux"), ou la reformulation automatique. La figure 6 présente l'architecture de la compréhension du langage naturel.

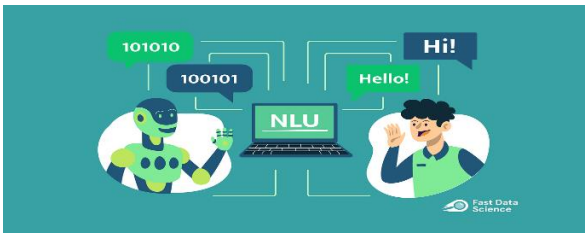


Figure 6: Natural Language Understanding [12]

- **Entraînement du modèle :**

Les textes prétraités et convertis en données numériques sont ensuite utilisés pour entraîner des modèles de machine learning. Durant cette phase, le modèle apprend à repérer des schémas et des relations dans les données. Il ajuste ses paramètres pour améliorer ses performances, et une fois entraîné, il peut traiter de nouveaux textes de façon autonome. Ce processus inclut aussi des phases de validation, d'évaluation et de réglage fin pour optimiser les résultats selon les tâches ciblées.

2. Les architectures des models du langage large

Les modèles de langage de grande taille reposent sur des architectures issues des Transformers. Selon la tâche à accomplir, ces modèles peuvent être construits selon trois grandes structures : encodeur, décodeur ou encodeur-décodeur. Chacune de ces architectures présente des spécificités adaptées à des besoins particuliers.

2.1 Architecture Encoder

Les modèles de type encodeur [10] sont conçus pour comprendre et encoder des séquences de texte. Ils sont particulièrement efficaces dans les tâches de compréhension du langage, comme la classification de texte, l'extraction d'entités nommées ou l'analyse de sentiment, il existe plusieurs modèles comme BERT, Transformer, etc. La figure 7 présente l'architecture du modèle encoder BERT [11] :

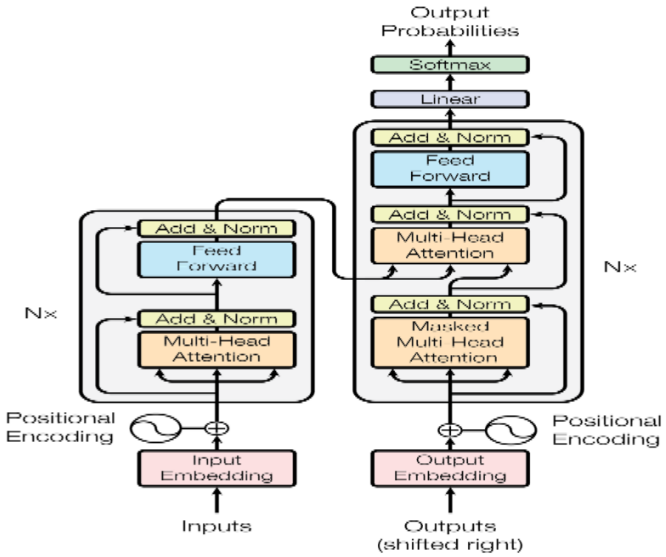


Figure 7: BERT Architecture [15]

2.2Architecture Decoder

Les modèles basés uniquement sur un décodeur sont optimisés pour la génération de texte. Contrairement aux encodeurs, le décodeur traite le texte de manière autorégressive, c'est-à-dire mot par mot, en s'appuyant uniquement sur le contexte précédent. Ces modèles excellent dans les tâches de complétion de texte, de rédaction automatique, de résumé ou encore de dialogue conversationnel, il existe plusieurs modèles d'architecture decoder comme GPT, Mistral, etc La figure 8 présente l'architecture du modèle decoder GPT [12] :

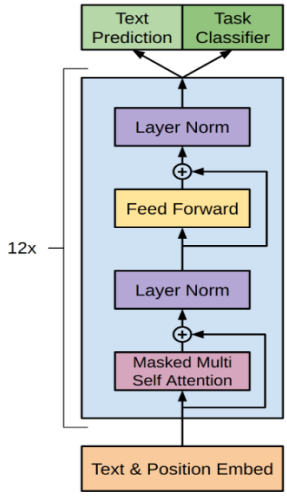


Figure 8: GPT Architecture

- **Architecture Encoder-Decoder :**

Les architectures encoder-decoder, aussi appelées seq2seq (sequence-to-sequence), combinent les forces des deux approches précédentes. L'encodeur traite et comprend la séquence d'entrée, puis le décodeur génère une séquence de sortie correspondante. Ce type de modèle est particulièrement adapté aux tâches nécessitant une transformation du texte, comme la traduction automatique, le résumé, ou la réponse à des questions complexes. La figure 9 présente l'architecture encoder-decoder [13] :

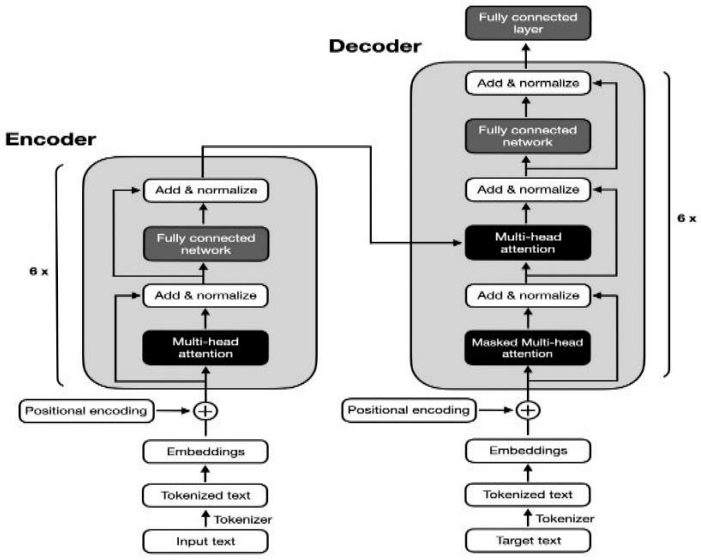


Figure 9: Encoder-Decoder Architecture [18]

3. Le Fine-tuning :

Le fine-tuning est un processus important en apprentissage automatique, notamment pour les modèles de langage pré-entraînés. Il consiste à ajuster les poids d'un modèle préexistant sur un ensemble de données spécifique afin qu'il puisse mieux répondre à des tâches particulières.

3.1. Fonctionnement du fine-tuning :

Le pré-entraînement d'un modèle de langage repose sur l'utilisation de vastes ensembles de données générales. Cette étape permet au modèle d'apprendre les structures fondamentales du langage, telles que la grammaire, la syntaxe, ainsi que les relations entre les mots et les phrases. L'objectif est d'acquérir une compréhension large du langage naturel, ce qui permet au modèle de traiter une variété de tâches linguistiques sans être spécifiquement entraîné pour chacune d'elles.

Une fois le pré-entraînement effectué, le modèle subit une phase de fine-tuning, où il est affiné sur un jeu de données spécifique au domaine d'application. Ce raffinement permet au modèle d'apprendre à identifier des motifs et des concepts propres à ce domaine, afin d'améliorer ses performances sur des tâches précises. Le fine-tuning implique également l'optimisation des hyperparamètres, des éléments cruciaux pour garantir une performance optimale du modèle. Parmi ces hyperparamètres figurent le taux d'apprentissage, la taille du lot (batch size) et le nombre d'époques. L'ajustement de ces paramètres permet de contrôler le processus d'apprentissage et d'assurer que le modèle s'adapte de manière efficace aux nouvelles données tout en minimisant les risques de surapprentissage.

La figure 10 présente le fonctionnement du fine-tuning

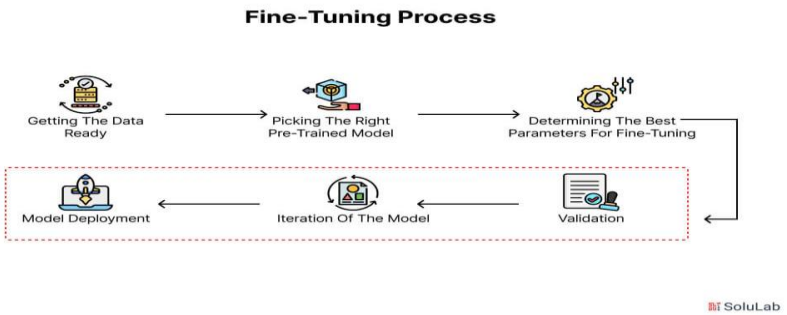


Figure 10: Traitement du Fine-tuning [19]

3.2. Importance du Fine-tuning :

Le fine-tuning permet de transformer un modèle de langage généraliste en un outil spécialisé, en l'adaptant à un domaine bien défini. Les modèles pré-entraînés possèdent une compréhension globale du langage, mais ils manquent souvent de précision lorsqu'il s'agit de traiter des contenus propres à un secteur particulier. En affinant leur apprentissage sur des données ciblées, on les aide à intégrer des connaissances spécifiques. Cette étape améliore considérablement la performance du modèle sur des tâches précises. En s'appuyant sur les acquis du pré-entraînement, le modèle devient plus pertinent dans ses réponses, car il est désormais capable d'interpréter correctement les nuances propres au domaine concerné.

Par ailleurs, le fine-tuning représente une solution économique en données. Plutôt que de construire un modèle de zéro, ce qui demande énormément de ressources, cette méthode permet d'obtenir des résultats convaincants avec un volume de données bien plus restreint, à condition que celui-ci soit représentatif et bien structuré.

3.3. Les méthodes du fine-tuning

L'adaptation d'un modèle de langage pré entraîné à un domaine spécifique, comme le secteur médical, repose sur plusieurs techniques de fine-tuning. Ces méthodes permettent de personnaliser les performances du modèle selon les besoins ciblés, tout en optimisant les ressources utilisées.

- **Fine-Tuning Complet (Full Fine-Tuning)** [14]**:**

Cette approche consiste à réentraîner l'ensemble des paramètres du modèle sur un jeu de données spécifique. Elle est particulièrement efficace pour une adaptation en profondeur, mais requiert des ressources importantes en termes de calcul et de mémoire. La figure 11 présente le fine-tuning du llms.

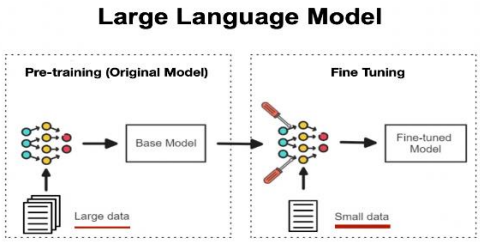


Figure 11: Fine-Tune LLMs [21]

- **Adaptation par Couches Intermédiaires (Adapter Layers)** [15] **:**

Au lieu de modifier tous les paramètres, cette méthode ajoute de petites couches (adapters) entre les blocs du modèle existant. Seules ces nouvelles couches sont entraînées, ce qui réduit

considérablement le coût computationnel et permet une plus grande flexibilité pour passer d'une tâche à une autre.

- **Adaptation par Faible Rang (Low-Rank Adaptation - LoRA)** [16] **:**

LoRA consiste à décomposer les matrices de poids en composantes de rang réduit, que l'on ajuste durant l'entraînement. Cette technique permet d'optimiser la mémoire tout en conservant une bonne capacité d'adaptation, notamment pour les très grands modèles.

- **Optimisation par Prompts (Prompt/Prefix Tuning)** [17] [18] **:**

Ici, le modèle reste figé, mais on apprend des vecteurs de prompts ou de préfixes insérés en entrée. Ces éléments influencent le comportement du modèle sans modifier ses poids internes. Cette approche est particulièrement adaptée aux cas où l'on dispose de peu de données.
La figure 12 présente Prompt tuning

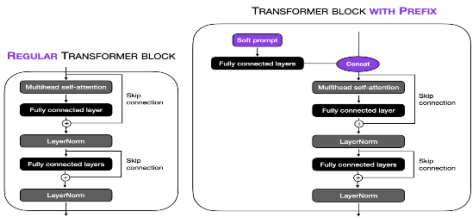


Figure 12: Prompt Tuning [26]

4. Retrieval-Augmented Generation

Le RAG [19] est une méthode qui vise à améliorer la génération de texte en intégrant un mécanisme de récupération d'informations. Plutôt que de se contenter des seules connaissances apprises pendant l'entraînement, cette approche permet au modèle d'aller chercher, en temps réel, des éléments d'information pertinents dans une base documentaire externe.

Lorsqu'une question est posée, le système commence par identifier, grâce à un module de recherche, les documents ou extraits de texte les plus liés à la requête. Ces éléments récupérés sont ensuite transmis au modèle génératif, qui s'en sert comme contexte pour formuler une réponse plus précise, factuelle et adaptée à la situation.

Cette stratégie présente plusieurs bénéfices : elle réduit les erreurs dues à des informations manquantes ou dépassées, améliore la qualité des réponses, et permet de s'adapter à des domaines spécifiques sans devoir réentraîner entièrement le modèle. Le RAG est particulièrement utile pour les tâches où la fiabilité des réponses est essentielle.

5. Base de données vectorielle

Une base de données vectorielle est un type de système de stockage et de recherche optimisé pour gérer des données représentées sous forme de vecteurs numériques. Ces vecteurs, appelés embeddings, traduisent le sens ou le contenu d'une information (texte, image, audio, etc.) dans un espace multidimensionnel. Contrairement aux bases de données classiques qui fonctionnent sur des correspondances exactes (matching symbolique), les bases vectorielles permettent des recherches par similarité sémantique : elles retrouvent les éléments les plus proches d'une requête, même si les mots utilisés sont différents.

Dans le contexte du traitement automatique du langage naturel, les textes sont encodés à l'aide de modèles comme BERT, Sentence Transformers ou BioBERT, afin de produire des vecteurs capturant leur signification. Ces vecteurs sont ensuite stockés dans une base vectorielle telle que ChromaDB [20], FAISS (Facebook AI Similarity Search) [21], ou Pinecone [22]. Lorsqu'une requête est émise, elle est également encodée en vecteur, et le système renvoie les passages les plus similaires du corpus en fonction d'une mesure de distance (souvent la distance cosinus ou euclidienne).

Ce type de base de données est particulièrement utile pour les systèmes d'IA générative augmentée par la recherche (RAG), car il permet de retrouver rapidement des contenus pertinents sur lesquels un modèle peut s'appuyer pour générer une réponse précise et contextualisée.

6. La différence entre RAG et Fine-Tuning

La différence entre le RAG et le Fine-Tuning est basé sur plusieurs critères. Voici un tableau comparant les deux méthodes.

Table 1: Différence entre RAG et Fine-tuning

Critère	**RAG**	**Fine-tuning**
Mémoire externe	Oui (base de connaissances ou base vectorielle externe)	Non (les connaissances sont intégrées dans les poids du modèle)
Actualisation des données	Facile (il suffit de mettre à jour la base de données)	Difficile (nécessite un nouvel entraînement pour toute mise à jour)

Temps d'entraînement	Pas d'entraînement requis (ou très minimal)	Long, surtout pour les gros modèles
Coût en ressources	Moins coûteux, car on n'altère pas les poids du modèle	Coût élevé, notamment en temps et en ressources matérielles (GPU, stockage)
Capacité d'adaptation	Très flexible pour de nouveaux domaines ou contenus	Moins flexible si les données changent souvent
Qualité des réponses	Dépend fortement de la qualité de la base de connaissances	Dépend de la qualité et de la diversité des données d'entraînement

7. Agent Conversationnel (Chatbot)

Un chatbot médical est un agent conversationnel intelligent conçu pour interagir avec les utilisateurs via le langage naturel, dans le but de fournir une assistance dans le domaine de la santé. Grâce à l'intégration de techniques avancées de traitement du langage naturel et d'intelligence artificielle, ce type de système est capable de comprendre les descriptions de symptômes fournies par les patients, d'en extraire les informations médicales pertinentes, et de proposer des pistes de diagnostic ou des conseils adaptés.

Dans ce projet, le chatbot agit comme un outil d'aide à l'analyse des symptômes, en s'appuyant sur des modèles de langage pré-entraînés et enrichis par des bases de connaissances médicales fiables. Il ne remplace pas un professionnel de santé, mais il vise à améliorer la pré-orientation des patients, en leur apportant une première évaluation claire et personnalisée.

Les chatbots se déclinent en plusieurs catégories selon leurs capacités et leur champ d'application. Voici les principaux types que l'on peut retrouver :

Table 2 : Types de chatbot

Type de Chatbot	**Caractéristiques**	**Exemples d'utilisation**
Chatbots simples	Fonctionnent avec des règles fixes, répondent aux questions fréquentes et offrent une interaction limitée via des boutons.	Support client, assistance technique
Chatbots spécialisés	Conçus pour des tâches précises dans un domaine spécifique.	- Transactionnels : commandes, réservations, paiements en ligne. - Marketing : promotion de produits, collecte de données clients.
Chatbots intelligents	Utilisent l'intelligence artificielle pour comprendre et s'adapter aux interactions, offrant des réponses plus naturelles et contextuelles.	- Conversationnels : interactions fluides avec compréhension du langage naturel. - Apprentissage automatique : amélioration continue grâce à l'analyse des échanges.
Chatbots hybrides	Combinent automatisation et intervention humaine pour une meilleure prise en charge des utilisateurs.	Service client avancé, gestion des requêtes complexes nécessitant un suivi humain.

Conclusion

Dans un premier temps, nous avons exploré le domaine d'application, en soulignant l'importance croissante de la télémédecine et de la santé connectée pour améliorer l'accessibilité aux soins, fluidifier les parcours de santé, et renforcer la prévention.

Dans un second temps, nous avons détaillé les concepts techniques fondamentaux sur lesquels repose le système proposé. Cela inclut le fonctionnement du traitement du langage naturel, les architectures des modèles de langage, les mécanismes d'adaptation par fine-tuning, ainsi que

l’approche RAG et une base de données vectorielle. La différence entre RAG et le fine-tuning a été clarifiée, et le rôle du chatbot médical comme interface interactive a été mis en évidence.

Chapitre 2 : Travaux Connexes

Ces dernières années, de nombreuses recherches ont été menées autour de l'utilisation de l'intelligence artificielle pour l'analyse des symptômes et la détection précoce des maladies. L'émergence de modèles de langage puissants, combinée à la disponibilité croissante de données médicales textuelles. Dans cette partie, je vais présenter un ensemble de travaux antérieurs ayant exploré des approches similaires ou complémentaires à mon projet. Cela inclut l'usage de modèles pré-entraînés dans un contexte médical.

I. Les modèles prés entrainés

Ces dernières années, l'apprentissage profond a connu une révolution grâce à l'émergence de modèles linguistiques massifs pré-entraînés sur des corpus textuels gigantesques. Contrairement aux approches traditionnelles qui nécessitent des données annotées, ces modèles apprennent de manière autonome à partir de vastes quantités de textes bruts, grâce à des tâches d'auto-supervision ingénieuses. Cette méthode permet ensuite d'adapter les modèles à des applications spécifiques via un réglage fin, transférant ainsi les connaissances acquises lors de la phase de pré-entraînement.

Parmi ces architectures, les modèles basés exclusivement sur des décodeurs se sont particulièrement distingués pour les tâches de génération de texte. Leur conception unidirectionnelle, où chaque mot est prédit en se basant uniquement sur les termes précédents, les rend exceptionnellement performants pour produire du langage de manière séquentielle et cohérente.

Le pionnier dans ce domaine, GPT (Generative Pre-trained Transformer), a établi de nouvelles références en matière de génération linguistique. Ses successeurs, comme GPT-2 [23] et GPT-3 [24], ont démontré des capacités remarquables en atteignant des performances impressionnantes sur des tâches variées allant de la création de contenu à la traduction automatique, souvent sans nécessiter d'ajustement spécifique. Leur force réside dans leur capacité à comprendre et exécuter des instructions complexes simplement grâce à des invites bien formulées.

Cette famille de modèles s'est considérablement enrichie avec des variantes comme :
Les architectures LLaMA [25] et Mistral [26], optimisées pour une utilisation efficace.
Les modèles PaLM [27] développés par Google, excellant dans les tâches de raisonnement.
Les solutions multilingues BLOOM et XGLM [28] , couvrant de nombreuses langues. Les alternatives ouvertes GPT-Neo et GPT-J [29] , accessibles à la communauté.

Ces systèmes atteignent leurs performances exceptionnelles grâce à plusieurs facteurs clés, une formation sur des corpus diversifiés, un nombre considérable de paramètres, et des mécanismes d'attention sophistiqués. Leur polyvalence leur permet de s'adapter à des contextes variés, bien que des défis persistent concernant la précision des informations générées et le contrôle des sorties.

Voici un tableau comparatif des principaux modèles de type décoder-only :

Table 3 : modèles decoder

Modèle	**Année de création**	**Nombre des paramètres**	**Token Limite**
GPT-3	2020	175B	2K
GPT-4	2023	~1T*	32K
LLaMA-2	2023	7B-70B	4K
Mistral	2023	7B	8K
PaLM 2	2023	340B*	32K
Falcon	2023	180B	2K

II. Les modèles prés entrainés dans la biomédecine

Les modèles de type decoder, comme ceux de la famille GPT, sont réputés pour leurs capacités en génération de texte. Cette performance suscite naturellement l'intérêt pour leur utilisation dans des domaines spécialisés comme la biomédecine. Cependant, plusieurs études ont montré que ces modèles, même dans leurs versions avancées telles que GPT-3, rencontrent des difficultés notables lorsqu'ils sont appliqués à des tâches biomédicales [30] . Ces résultats suggèrent que les modèles decoder généralistes sont peu adaptés à des contextes très spécialisés sans adaptation préalable.

Pour améliorer cette situation, certains travaux ont tenté de réentraîner des modèles GPT sur des textes biomédicaux. C'est le cas de DARE [31] , qui représente une tentative précoce de spécialisation en pré-entraînant un modèle GPT sur un corpus limité constitué uniquement de résumés PubMed. Toutefois, son utilisation reste ciblée sur l'augmentation de données pour des tâches spécifiques, comme l'extraction de relations.

Plus récemment, d'autres approches ont vu le jour pour adapter les modèles decoder aux besoins du domaine médical. Par exemple, BioGPT [32] est un modèle basé sur l'architecture GPT, mais pré-entraîné dès le départ sur un très large corpus biomédical issu de PubMed. Grâce

à ce choix de données et à une pré-formation adaptée, BioGPT parvient à mieux comprendre les spécificités du langage médical, ce qui le rend plus performant sur des tâches telles que la génération de résumés, la réponse à des questions cliniques, ou encore l'analyse de relations entre entités biomédicales.

De manière similaire, PubMedGPT adopte une stratégie comparable en se focalisant uniquement sur les textes scientifiques de PubMed, mais avec l'objectif clair de construire un modèle de génération exclusivement dédié au domaine biomédical.

L'ensemble de ces travaux montre que pour exploiter pleinement le potentiel des modèles decoder dans le contexte médical, il est crucial de les entraîner directement sur des données du domaine. Cette spécialisation permet non seulement d'améliorer la qualité des réponses générées, mais aussi d'adapter le vocabulaire et les représentations internes du modèle aux exigences du langage biomédical.

III. Avantages et Limites des Méthodes Existantes :

Voici un tableau qui représente les avantages et les limites des méthodes existantes bassées sur les modèles decoder dans le domaine de la biomédecine :

Table 4: Les modèles existants

Modèle	**Avantages**	**Limites**
GPT	- Puissant pour la génération de texte - Facilement accessible	- Non adapté au vocabulaire biomédical - Performances faibles en biomédecine
DARE	- Adapté partiellement au domaine médical - Utile pour l'augmentation de données	- Corpus limité (résumés PubMed seulement) - Usage restreint
BioGPT	- Pré-entraîné sur des textes biomédicaux - Bon sur les tâches de génération	- Basé uniquement sur PubMed - Moins adapté aux données cliniques

PubMedGPT	- Spécialisé sur le domaine biomédical - Vocabulaire plus précis	- Manque de diversité dans les sources - Moins efficace en clinique

IV. Exemple d'application

Avec l'essor de la santé numérique, plusieurs outils intelligents ont été développés pour automatiser cette phase en utilisant l'intelligence artificielle et des bases de données médicales. Parmi les exemples notables :

- **Ada Health** [33]:

Cette application mobile développée en Allemagne propose un assistant médical intelligent capable d'analyser les symptômes renseignés par l'utilisateur. En posant une série de questions, Ada fournit une liste de causes possibles ainsi que des conseils sur la nécessité de consulter un professionnel de santé.

- **Symptomate** [34]:

Ce système, utilisé à la fois par les patients et les professionnels, repose sur une base de données médicale actualisée. Il guide l'utilisateur à travers un questionnaire interactif et offre une évaluation préliminaire des symptômes, accompagnée d'un niveau de gravité estimé.

- **Buoy Health** [35]:

Développée aux États-Unis, cette plateforme conversationnelle permet aux utilisateurs de décrire leurs symptômes en langage naturel. L'IA utilise ces informations pour proposer des hypothèses diagnostiques, basées sur des sources cliniques validées.

V. Choix de l'Approche et Valeur Ajoutée

Dans le cadre de ce projet, j'ai choisi d'adopter une approche basée sur le concept de Retrieval-Augmented Generation, en y associant une base de données vectorielle implémentée via ChromaDB. Cette méthode présente un avantage majeur dans les systèmes de question-réponse médicaux, elle permet au modèle de s'appuyer non seulement sur sa capacité linguistique, mais aussi sur des sources d'information médicales externes au moment même de la génération.

Concrètement, lorsqu'un utilisateur soumet une requête, celle-ci est convertie en vecteur et comparée aux documents indexés dans ChromaDB, qui contient des textes médicaux fiables

tels que des articles cliniques, fiches pathologiques ou recommandations de bonnes pratiques. Les fragments les plus pertinents sont alors sélectionnés et injectés comme contexte dynamique dans le prompt du modèle. Cela permet de formuler une réponse plus précise, contextualisée et directement fondée sur des données à jour.

L'approche RAG constitue ainsi une valeur ajoutée essentielle, car elle contourne les limites traditionnelles des modèles "fermés" en leur offrant un accès en temps réel à une base de connaissances médicale. Cette capacité d'enrichissement documentaire contextuel renforce non seulement la fiabilité des réponses, mais aussi leur explicabilité, ce qui est fondamental dans le domaine de la santé.

Conclusion :

Ce chapitre a permis de passer en revue les principaux travaux liés à l'utilisation des modèles de langage dans le domaine médical, en mettant l'accent sur les approches pré-entraînées et leur adaptation au contexte biomédical. Nous avons examiné les performances, les avantages et les limites de ces modèles. Ces constats justifient l'adoption d'une approche hybride dans ce projet, combinant les capacités génératives d'un LLM avec un mécanisme de récupération d'information externe RAG, dans le but d'obtenir des réponses plus contextualisées, fiables et évolutives.

Chapitre 3 : Description du projet

Ce projet vise à développer un chatbot médical spécialisé dans la fourniture d'informations et d'assistance aux utilisateurs dans le domaine de la santé. La méthodologie employée combine une architecture de système axée sur la récupération d'informations avec la puissance des grands modèles de langage (LLMs) pré-entraîné, pour générer des réponses pertinentes. Une étape clé de cette approche est l'utilisation d'une base de données vectorielle (par exemple, ChromaDB) pour stocker et récupérer efficacement des informations médicales pertinentes. Cette intégration permet au système de fournir des réponses basées sur des connaissances médicales spécifiques et contextuellement riches. L'objectif est de créer un outil qui puisse offrir un support informatif et contextuellement approprié aux requêtes des utilisateurs concernant la santé.

I. Workflow du projet

Le workflow du projet est organisé en plusieurs étapes, chacune contribuant à la conception, au développement et du chatbot médical. À ce stade, je vais expliquer la méthode de Retrieval-Augmented Generation, en détaillant son fonctionnement et son rôle dans l'amélioration des réponses générées par le modèle. La figure 13 présente l'architecture d'une configuration RAG, montrant le processus de segmentation des documents, leur stockage dans une base de données vectorielle, et l'utilisation des résultats pour générer des réponses pertinentes via les modèles de langage (LLMs)

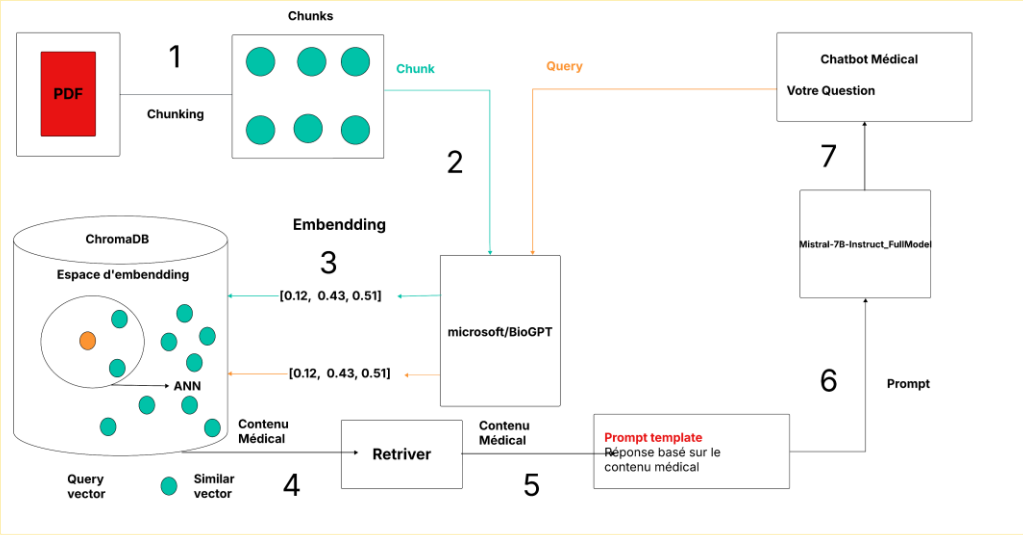


Figure 13: Architecture Système

1. **Créer des morceaux(chunks)**

La première étape consiste à décomposer ces connaissances supplémentaires en morceaux avant de les intégrer et de les stocker dans la base de données vectorielle.

Voici quatre stratégies de découpage pour RAG :

- **Morceau de taille fixe :**

La méthode la plus simple pour découper un texte consiste à le diviser en segments de taille uniforme, selon un nombre prédéfini de caractères, de mots ou de jetons.

Cependant, une séparation directe peut perturber le sens des phrases. Pour éviter cela, il est recommandé d'ajouter un chevauchement entre deux segments consécutifs, comme illustré par la partie bleue (Overlap) sur la figure 14.

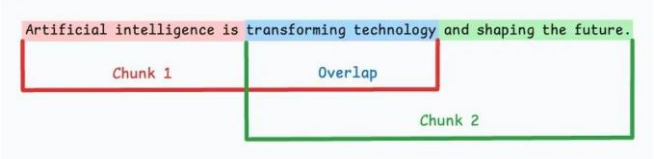


Figure 14: Découpage en morceaux de taille fixe avec chevauchement. [44]

Cette approche est facile à mettre en œuvre et permet un traitement simplifié, car tous les morceaux sont de taille égale. Toutefois, elle présente une limite : elle risque de couper les phrases ou les idées, ce qui peut disperser des informations importantes entre plusieurs segments.

- **Morceau sémantique**

L'idée est de découper le texte en unités qui ont du sens, comme des phrases, des paragraphes ou des sections thématiques.

— On commence par le premier segment et on l'intègre.

— Si ce segment est très similaire au suivant, ils sont regroupés pour former un bloc.

— Cela continue jusqu'à ce que la similarité diminue fortement, marquant la fin d'un bloc.

— À ce moment, un nouveau segment commence, et le processus se répète.

Comme illustré dans la figure 15, ce type de découpage permet de regrouper des segments ayant une forte similarité tout en conservant le sens naturel du texte. Cela améliore la cohérence des blocs, ce qui permet au modèle de produire des réponses plus précises et pertinentes.

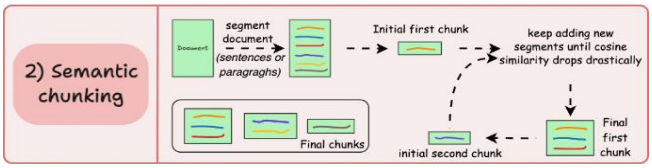


Figure 15: Découpage sémantique basé sur la similarité cosinus.

Cependant, un défi reste de définir un seuil pour mesurer la similarité entre les segments, ce qui peut varier d'un texte à un autre.

- **Segmentation récursive**

La segmentation récursive consiste à diviser un texte en blocs en utilisant des séparateurs naturels, tels que les paragraphes ou les sections thématiques.

(a) Tout d'abord, le texte est segmenté en blocs principaux.

(b) Si un bloc dépasse une taille prédéfinie, il est divisé en sous-blocs plus petits.

(c) En revanche, si le bloc respecte la limite de taille, il reste inchangé sans autre fractionnement.

Comme illustré dans la figure 16, le premier paragraphe est divisé en morceaux plus petits tandis que le second reste intact.

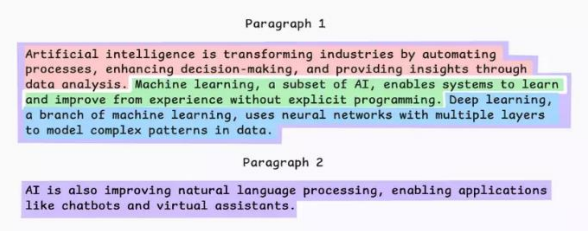


Figure 16: Segmentation récursive avec découpage en sous-blocs.

Cette méthode permet de préserver le flux naturel du langage et de conserver les idées complètes, contrairement aux découpages fixes. Toutefois, elle présente une contrainte : elle nécessite des ressources supplémentaires en termes de calcul et de complexité de mise en œuvre.

- **Morceautage basé sur la structure du document**

Cette méthode utilise la structure naturelle du document (titres, sections et paragraphes) pour définir les limites des blocs.

De cette manière, l'intégrité du texte est préservée, car le découpage s'aligne sur les sections logiques du document. Par exemple, un titre, une introduction ou une section thématique forme un bloc distinct.

Comme illustré dans la figure 17, chaque partie du document (titre, introduction, sections et conclusion) devient un chunk. Cela facilite le traitement des informations structurées tout en conservant le sens intact.

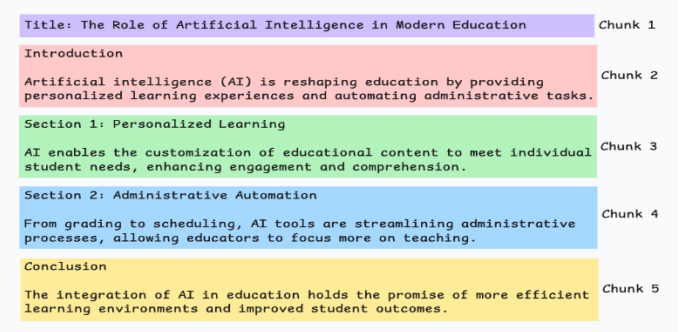


Figure 17: Morceautage basé sur la structure du document.

Cependant, cette approche suppose que le document possède une structure claire, ce qui n'est pas toujours le cas. De plus, les segments peuvent varier en longueur et parfois dépasser les limites du modèle, nécessitant un fractionnement supplémentaire.

2. Générer des intégrations (embeddings)

Après avoir découpé le texte en morceaux (chunks), j'ai utilisé un modèle d'intégration pour transformer ces segments en représentations numériques appelées embeddings.

Les embeddings sont des vecteurs numériques qui capturent le sens et le contexte des morceaux de texte. Chaque chunk est converti en un vecteur de valeurs numériques, permettant au modèle de comprendre les relations sémantiques entre les différents segments.

Comme illustré dans la figure 18, chaque chunk est intégré à l'aide du modèle d'embedding, produisant une matrice où chaque ligne représente un segment sous forme numérique.

Cette étape est cruciale pour permettre au modèle de langage de traiter les données efficacement et d'identifier les informations pertinentes.

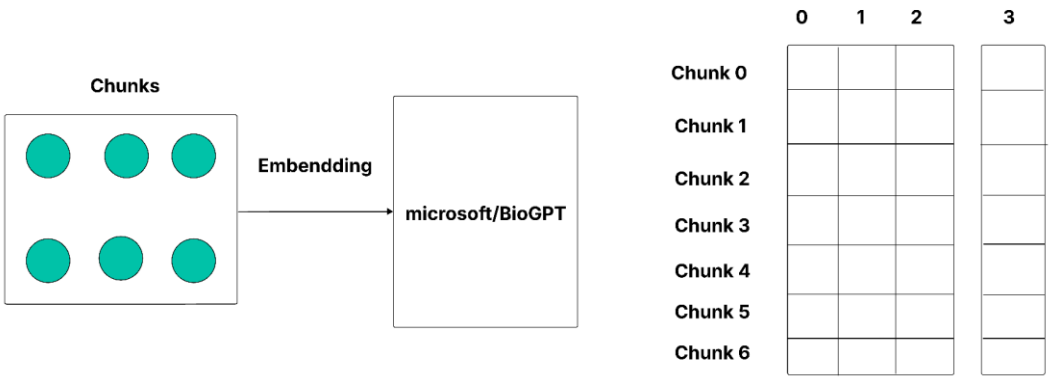


Figure 18: Génération des embeddings à partir des chunks.

3. Stocker les embeddings dans une base de données vectorielle

Une fois les intégrations (embeddings) générées, elles sont stockées dans une base de données vectorielle. Cette base joue le rôle de mémoire pour l'application RAG, en conservant toutes les informations nécessaires pour répondre aux requêtes des utilisateurs.

Comme illustré dans la figure 19, cette base de données vectorielle contient non seulement les embeddings mais également les métadonnées et le contenu original des morceaux de texte (chunks). Cela permet d'ajouter des informations supplémentaires, si nécessaire, pour affiner les résultats.

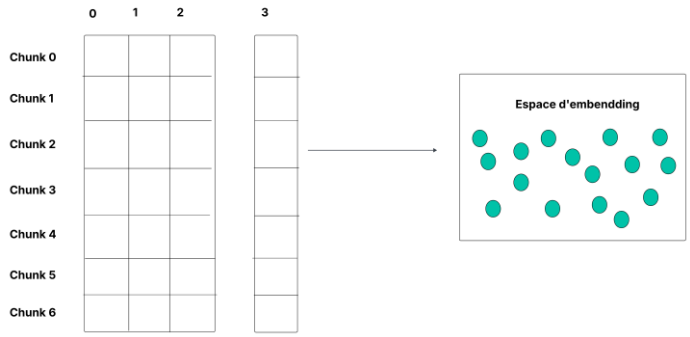


Figure 19: Stockage des embeddings dans une base de données vectorielle.

Grâce à cette structure, il devient possible de rechercher rapidement et efficacement les informations pertinentes, facilitant ainsi la génération de réponses précises.

4. Interface utilisateur

L'utilisateur saisit une requête dans l'application, qui correspond à une chaîne de texte représentant les informations recherchées. Comme illustré dans la figure 30, l'interface utilisateur permet à l'utilisateur d'entrer sa question, qui sera ensuite traitée par le système.

5. Intégrer la requête

La requête saisie par l'utilisateur est convertie en un vecteur grâce au même modèle d'intégration utilisé précédemment pour transformer les morceaux (chunks) en embeddings.

Cette transformation permet de représenter la requête sous forme numérique, facilitant sa comparaison avec les embeddings existants.

Comme illustré dans la figure 20, la requête est d'abord transformée en embedding par le modèle d'intégration, puis représentée sous forme de vecteurs numériques dans une matrice.

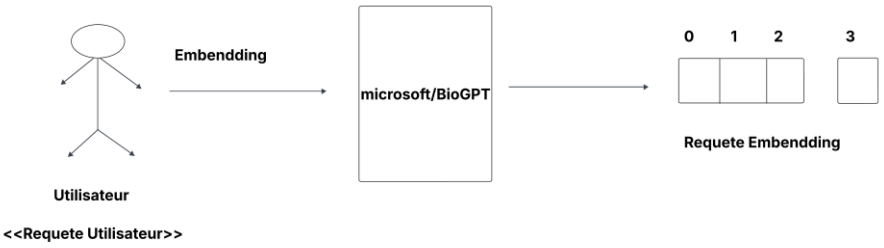


Figure 20: Conversion de la requête utilisateur en embedding vectoriel.

Cette étape est essentielle pour retrouver les informations pertinentes stockées dans la base de données vectorielle.

6. Récupérer des morceaux similaires

Une fois la requête utilisateur transformée en vecteur, elle est comparée aux vecteurs existants dans la base de données vectorielle afin de retrouver les informations les plus pertinentes.

Comme illustré dans la figure 21, la base de données effectue une recherche approximative du voisin le plus proche (ANN - Approximate Nearest Neighbor), en identifiant les vecteurs les plus similaires au vecteur de requête (en jaune). Ces vecteurs similaires (en bleu) représentent les morceaux de texte les plus proches en termes de sens.

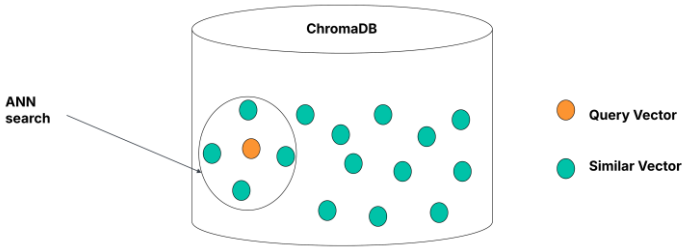


Figure 21: Recherche des vecteurs similaires dans la base de données vectorielle.

La base renvoie alors les k morceaux les plus similaires, où k est un paramètre prédéfini. Ces morceaux sont représentés dans la figure 22 sous forme de chunks similaires contenant les informations pertinentes.

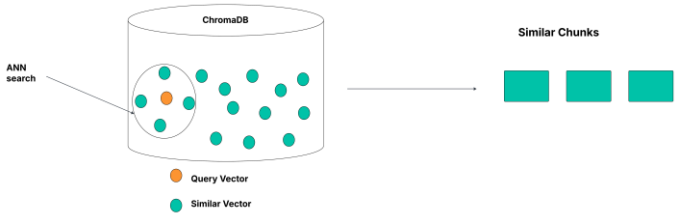


Figure 22: Morceaux similaires récupérés pour la requête.

Cette étape permet de récupérer les morceaux de texte les plus pertinents à partir de la base de données vectorielle. Ces morceaux servent ensuite de base pour générer une réponse précise et adaptée à la requête utilisateur.

II. Les modèles utilisés

Les grands modèles de langage (LLM) sont devenus des outils indispensables dans le domaine de l'intelligence artificielle. Ils jouent un rôle crucial dans de nombreuses applications, notamment en IA générative et en traitement du texte.

Après une étude approfondie des modèles de langage de grande taille pour le développement d'un chatbot médical, j'ai conclu que Medical_Doctor_AI_LoRA-Mistral-7B-Instruct_FullModel et Microsoft/BioGPT sont le choix le plus adapté.

- **Modèle de Langage (LLM) :**

Le modèle de langage principal utilisé est "Medical_Doctor_AI_LoRA-Mistral-7B-Instruct_FullModel".

Ce modèle est une version affinée ou spécialisée du modèle de base Mistral-7B, optimisée par l'application de la technique LoRA (Low-Rank Adaptation) pour les tâches liées au domaine médical.

Mistral-7B est lui-même un grand modèle de langage, et l'adaptation LoRA permet d'ajuster efficacement ce modèle aux spécificités du langage médical et des connaissances cliniques, sans nécessiter un réentraînement complet.

Dans mon projet, le modèle est utilisé pour générer des réponses aux requêtes des utilisateurs. Il traite les questions ou demandes (éventuellement combinées avec des informations récupérées) et produit une réponse textuelle ciblée sur le domaine médical.

La figure suivante représente le modèle Mistral dans la Biomédecine :

- **Modèle d'Embedding (pour la Base de Données Vectorielle) :**

Le modèle d'embedding utilisé pour créer les représentations vectorielles des textes est Microsoft BioGPT.

Microsoft BioGPT est un modèle de langage pré-entraîné spécifiquement sur de vastes quantités de littérature biomédicale. Il est conçu pour capturer les nuances sémantiques et les relations complexes au sein du texte médical.

Ce modèle est utilisé pour convertir le texte (à la fois les requêtes des utilisateurs et les documents provenant de la base de connaissances médicale) en vecteurs numériques.

Ces vecteurs encodent la signification sémantique du texte, ce qui permet de quantifier la similarité entre les requêtes et les documents.

Cette capacité est essentielle pour la récupération d'informations, car elle permet au système d'identifier les documents les plus pertinents pour une requête donnée en comparant leurs vecteurs.

L'utilisation de BioGPT offre l'avantage d'exploiter un modèle spécialement adapté au domaine biomédical, ce qui peut conduire à des représentations vectorielles plus précises et à une meilleure performance de la recherche de similarité.

La figure suivante représente le modèle Microsoft BioGPT :

Conclusion :

Dans ce chapitre j'ai exploré le développement d'un chatbot médical en tirant parti de la puissance des grands modèles de langage et des techniques de récupération d'informations. L'intégration d'un LLM spécialisé dans le domaine médical, tel que "Medical_Doctor_AI_LoRA-Mistral-7B-Instruct_FullModel", et d'un modèle d'embedding biomédical, comme Microsoft BioGPT, a permis de construire un système capable de fournir des réponses informatives et contextuellement pertinentes aux requêtes des utilisateurs.

Chapitre 4 : Réalisation et évaluation

L’évaluation du système développé constitue une étape essentielle pour valider sa pertinence, son efficacité et sa robustesse. Ce chapitre vise à mesurer dans quelle mesure le chatbot médical répond aux attentes des réponses, des interactions et de compréhension des requêtes formulées en langage naturel. Pour ce faire, différentes métriques d’évaluation sont utilisées, accompagnées de visualisations permettant d’interpréter les résultats de manière claire. Cette étape permet également d’identifier les points d’amélioration, en vue d’optimiser le déploiement et l’usage du système dans un contexte réel.

I. Métriques de performance

Pour évaluer la performance du chatbot médical, plusieurs indicateurs sont utilisés afin de mesurer la qualité des réponses générées et la pertinence des résultats retournés par le système. Parmi les métriques principales, on distingue :

- **Accuracy :**

Cette métrique mesure la proportion de réponses correctes parmi l’ensemble des réponses générées par le chatbot. Elle permet de vérifier la capacité globale du système à produire des informations médicales fiables.

- **Similarité Sémantique :**

Le score de similarité sémantique (par exemple : cosine similarity sur des embeddings) évalue à quel point la réponse générée est proche, en termes de sens, de la réponse attendue. Cette mesure est adaptée aux réponses ouvertes formulées en langage naturel.

- **Retrieval Precision :**

Elle correspond à la proportion de documents réellement pertinents parmi ceux que le module RAG a extraits de la base vectorielle. Cette métrique est cruciale pour s'assurer que le contexte fourni au modèle est pertinent.

- **Retrieval Recall :**

Cette métrique mesure la capacité du système à retrouver tous les documents pertinents présents dans la base. Un bon rappel signifie que le système n’a pas omis d’informations importantes dans sa recherche.

- **F1-score :**

Le F1-score, qui combine la précision et le rappel, offre une vue globale de l’équilibre entre la quantité de bonnes informations extraites et la quantité de bruit introduit. Il est utilisé tant pour l’évaluation des documents récupérés que pour les réponses générées

- **Score de Cohérence de Réponse :**

Cette métrique évalue dans quelle mesure la réponse produite par le modèle est logique, bien structurée et fidèle aux documents retrouvés. Elle peut être mesurée via des annotations humaines ou des scores automatisés comme BLEU, ROUGE et BERTScore.

II. Visualisation des résultats

La visualisation des résultats constitue une étape essentielle pour analyser les performances du chatbot médical et identifier ses points forts ainsi que ses axes d'amélioration. Divers graphiques ont été utilisés afin de représenter de manière intuitive les métriques évaluées précédemment.

- **Histogrammes des scores de similarité :**

Ils illustrent à quel point les réponses générées par le modèle sont proches du contenu médical de référence, mesuré à l'aide d'indicateurs de similarité sémantique.

L'histogramme suivant présente les réponses générées par le modèle microsoft/BioGPT :

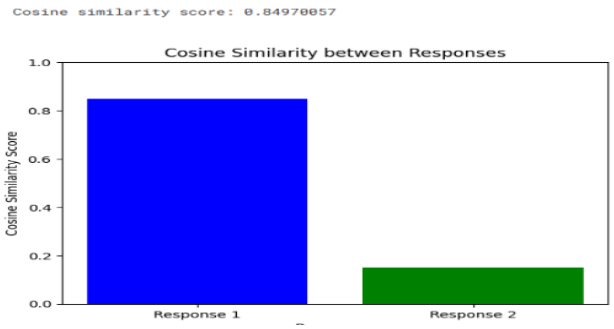


Figure 23: similarité score pour le modèle microsoft/BioGPT

Le graphique présenté illustre la mesure de similarité cosinus entre deux réponses générées par le modèle microsoft/BioGPT dans un contexte d'analyse biomédicale. Cette métrique permet d'évaluer dans quelle mesure les réponses produites sont sémantiquement proches d'un contenu de référence ou d'une réponse attendue.

L'axe vertical représente le score de similarité cosinus, dont la valeur varie entre 0 et 1. Plus ce score se rapproche de 1, plus les réponses comparées sont jugées similaires sur le plan sémantique. Inversement, une valeur proche de 0 indique une forte divergence dans le contenu ou le sens.

Dans ce cas précis :

La première réponse atteint un score élevé d'environ 0.85, ce qui suggère qu'elle est très proche sémantiquement du texte de référence, traduisant une bonne compréhension du modèle.

À l'inverse, la deuxième réponse n'atteint qu'environ 0.15, indiquant une faible similarité et donc une réponse probablement hors sujet ou mal formulée dans le contexte médical attendu.
Le score global de 0.8497 affiché en haut du graphique renforce cette conclusion. Dans l'ensemble, le modèle BioGPT est capable de générer des réponses cohérentes, pertinentes et alignées sur les documents médicaux fournis. Cependant, cette évaluation met également en évidence la variabilité possible dans la génération, soulignant l'intérêt d'intégrer des mécanismes de vérification ou de récupération contextuelle pour renforcer la fiabilité des réponses.

- **Graphique de F1-score :**

Utilisé pour comparer les performances du modèle sur différents seuils, ce graphique met en évidence la robustesse et la cohérence du système dans divers scénarios.
La figure suivante présente la courbe de F1-Score :

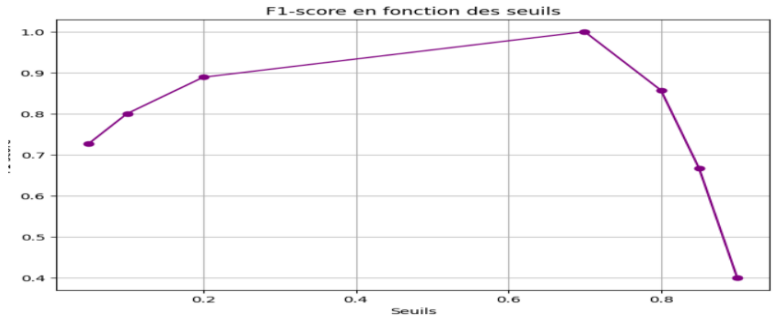


Figure 24: Courbe de F1-Scores

Le graphique présenté illustre comment le F1-score varie en fonction des seuils de décision appliqués par le système. Ces seuils déterminent à partir de quel niveau de confiance une réponse du modèle est considérée comme pertinente médicalement.
L'axe horizontal indique différents seuils de classification, tandis que l'axe vertical représente le F1-score, une mesure qui combine précision (le taux de réponses correctes parmi celles proposées) et rappel (la capacité à retrouver toutes les réponses médicalement pertinentes).
On constate que le F1-score augmente avec le seuil jusqu'à atteindre un pic vers 0.65, indiquant que le système parvient à équilibrer efficacement la détection des symptômes vrais tout en limitant les faux positifs. Ce point représente donc le meilleur compromis entre détecter les bons symptômes associés à une pathologie et éviter les suggestions médicales erronées.
Au-delà de ce seuil optimal, la performance diminue fortement : le système devient trop strict et néglige des cas de symptômes valides, ce qui pourrait entraîner des erreurs de diagnostic ou

des retards de détection. Inversement, des seuils trop bas génèrent plus de bruit, en intégrant des réponses moins pertinentes.

Dans le contexte médical, cette courbe démontre qu'un ajustement précis du seuil de confiance est essentiel pour garantir à la fois la fiabilité clinique des résultats et leur utilité pratique pour l'orientation diagnostique. Le bon réglage de ce seuil permet au système de contribuer efficacement à une première évaluation des symptômes, tout en maintenant un niveau de précision acceptable pour une utilisation en santé numérique.

III. Evaluation des performances

L'évaluation des performances repose sur l'analyse de plusieurs critères qualitatifs et quantitatifs, mesurant à la fois la pertinence des réponses et la fluidité de l'interaction avec l'utilisateur.

- **Précision des réponses :**

Le chatbot a été testé sur un ensemble de questions médicales couvrant différents niveaux de complexité. Les réponses générées ont été comparées à des sources médicales fiables afin de vérifier leur exactitude. Les résultats montrent que le modèle, combiné à l'approche RAG, offre un bon taux de précision, en particulier pour les requêtes symptomatiques courantes.

Dans les figures suivantes j'ai fait le test du prompt avant l'approche RAG et Après :

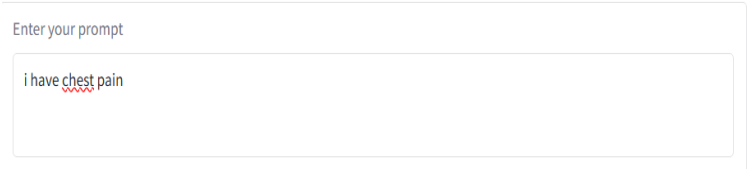


Figure 25: Prompt

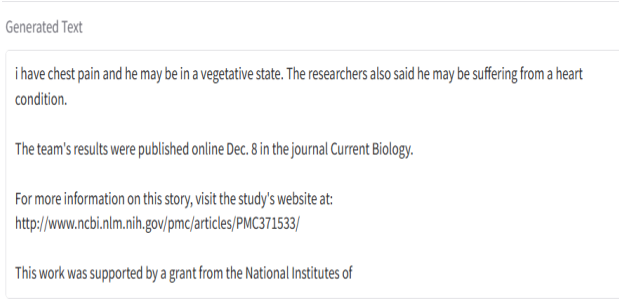


Figure 26: Réponse avant RAG

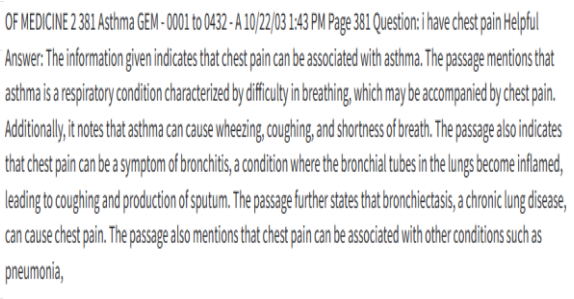


Figure 27: Réponse après RAG

- **Comparaison entre les métriques :**

L'objectif de cette comparaison est de mettre en évidence les différences entre l'évaluation directe des modèles du chapitre état de l'art (sans récupération contextuelle) et l'évaluation du

système RAG complet, qui combine recherche documentaire et génération de réponses enrichies.

Les modèles ont été évalués sur leurs capacités intrinsèques à générer des réponses médicales pertinentes, sans l'appui d'un système de récupération externe :

Table 5: Les performances des modèles du chapitre état de l'art

Modèle	**Précision**	**Rappel**	**F1-score**
GPT	0.265	0.298	0.279
DARE	0.381	0.364	0.372
BioGPT	0.417	0.447	0.408
PubMedGPT	0.403	0.432	0.415

Ces scores traduisent la capacité du modèle à restituer les bonnes réponses, mais sans contexte documentaire réel, ce qui peut limiter la précision dans certains cas.

Le système RAG a été évalué globalement sur sa capacité à combiner recherche sémantique et génération contextuelle. Voici les métriques utilisées :

Table 6: Les métriques du RAG

Métrique	**Valeur**	**Interprétation**
Accuracy	0.60	Taux de réponses correctes
Cosine Similarity	0.84	Alignement sémantique entre la réponse générée et la source extraite
Retrieval Precision	0.66	Pertinence des documents retrouvés dans la base ChromaDB
Rouge Score	0.54	Recouvrement lexical avec une réponse attendue
Bleu Score	0.80	Qualité linguistique de la génération
BERT Score (F1)	0.95	Proximité sémantique fine avec la réponse de référence

Afin de mieux comprendre les apports respectifs des modèles existants et du système RAG dans sa globalité, une comparaison a été réalisée. Cette analyse vise à mettre en évidence les

différences en termes de précision, de qualité de génération, de cohérence contextuelle et d'adaptabilité.

Voici un tableau qui montre cette comparaison :

Table 7: Comparaison entre les modèles existants et le système RAG

Aspect Evalué	**Modèles existants**	**Système RAG**
Précision sans contexte	Moyenne (≈ 40 %)	Améliorée grâce à l'intégration du contexte médical
Rappel d'information	Dépend du modèle	Fiable grâce à la recherche dans ChromaDB
Fidélité textuelle	Variable selon le modèle	Très bonne (ROUGE, BLEU élevés)
Cohérence sémantique	Limitée	Excellente (BERT Score à 0.95 et similarité cosinus à 0.84)
Adaptabilité	Limitée aux données vues à l'entraînement	Flexible via mise à jour des documents
Robustesse aux requêtes ouvertes	Moyenne	Élevée, car supportée par récupération ciblée

IV. Déploiement de solution proposée

Le développement de l'interface utilisateur constitue une étape cruciale pour assurer une interaction fluide et intuitive entre l'utilisateur et le chatbot médical. L'objectif principal est de concevoir une interface simple, ergonomique et accessible qui favorise un échange naturel, tout en offrant une expérience utilisateur agréable et rassurante.

L'interface a été développée de manière à répondre aux besoins d'un chatbot médical :

- **Boîte de dialogue intuitive :**

L'utilisateur peut poser ses questions ou exprimer ses préoccupations dans une boîte de texte dédiée.

- **Affichage des réponses :**

Les réponses générées par le modèle sont affichées immédiatement sous forme de messages clairs et rassurants.

- **Historique des conversations :**

L'historique des échanges est conservé pour permettre à l'utilisateur de suivre la progression de la conversation.

La figure suivante présente une capture d'écran de l'interface utilisateur du chatbot médical développée avec Gradio Live :

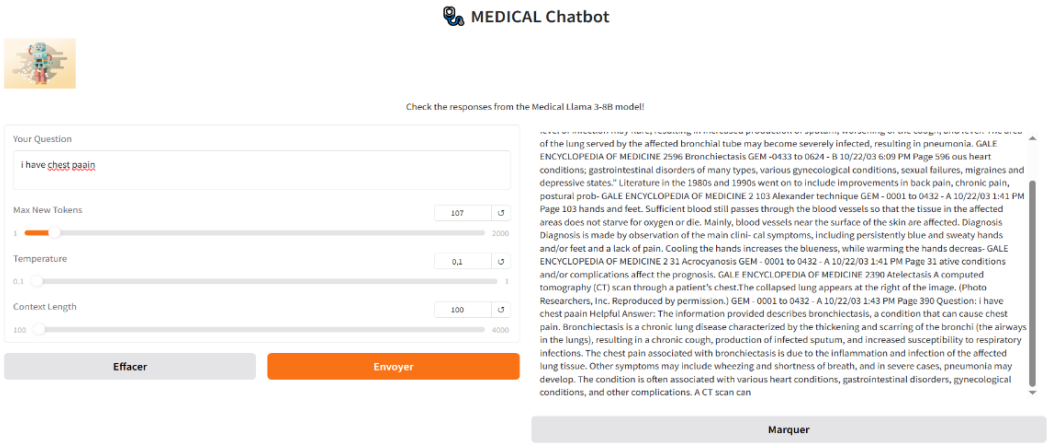


Figure 28: Capture d'écran de l'interface utilisateur du chatbot

Le chatbot est conçu pour interpréter ce type de requête médicale et fournir une réponse informative. Il simule le comportement d'un assistant médical intelligent, capable d'extraire des informations à partir d'une base de connaissances médicales.

Trois curseurs sont visibles et permettent d'ajuster le comportement du modèle :

Max New Tokens : nombre maximal de tokens que le modèle peut générer en réponse.

Temperature : contrôle la créativité du modèle. Une température basse (comme ici) favorise des réponses plus déterministes et factuelles, idéales pour le domaine médical.

Context Length : longueur du contexte pris en compte. Ici, le modèle utilise les 100 derniers tokens pour répondre, ce qui aide à garder du contexte conversationnel.

Le flux d'interaction utilisateur se déroule comme suit :

L'utilisateur saisit une question ou une préoccupation dans la boîte de dialogue prévue à cet effet.

La requête est transmise au modèle de langage Medical_Doctor_AI_LoRA-Mistral-7B-Instruct_FullModel via une architecture backend développée en Python.

Le modèle génère une réponse adaptée en analysant le contexte conversationnel.

La réponse est affichée dynamiquement dans l'interface sous forme d'un message clair et structuré.

Conclusion

Dans ce chapitre j'ai démontré la pertinence de l'approche adoptée, notamment grâce à l'intégration du mécanisme RAG et de la base vectorielle Chroma DB. Les résultats obtenus à travers différentes métriques telles que la précision, le rappel, les scores F1, BERTScore ou encore la similarité cosinus confirment que le modèle est capable de générer des réponses cohérentes. Après j'ai fait une comparaison entre les modèles existants et le système RAG. Enfin j'ai fait un test a travers l'interface utilisateur du chatbot.

Conclusion générale et Perspectives

Ce projet a permis de concevoir et de développer un système intelligent d'analyse des symptômes à des fins de détection précoce des maladies, en combinant les capacités des grands modèles de langage (LLM) avec l'approche Retrieval-Augmented Generation (RAG). L'objectif principal était d'améliorer la pertinence des réponses médicales générées en fournissant au modèle un accès dynamique à une base documentaire spécialisée, construite à partir de ressources fiables et indexée via ChromaDB.

Les différentes étapes du projet depuis la préparation des données médicales jusqu'à l'évaluation du système ont confirmé la pertinence de l'architecture choisie. L'intégration de la recherche sémantique dans la génération de texte permet non seulement d'enrichir les réponses, mais aussi de contourner les limitations liées aux modèles entraînés de manière statique. Les résultats obtenus ont mis en évidence la supériorité de cette approche par rapport aux modèles classiques utilisés, en termes de précision, de contextualisation et de cohérence des réponses.

Perspectives

Plusieurs pistes d'amélioration et de développement futur peuvent être envisagées :

- Extension du corpus médical : en enrichissant la base documentaire avec des sources plus diversifiées (guidelines cliniques, bases pharmacologiques, études récentes), le système gagnerait en couverture et en actualité.
- Intégration multilingue : adapter le système à d'autres langues permettrait d'élargir son accessibilité, notamment dans les contextes internationaux ou multilingues.
- Amélioration de l'interface utilisateur : un travail supplémentaire sur l'ergonomie, l'interactivité et la personnalisation pourrait renforcer l'expérience utilisateur.
- Validation clinique : des collaborations avec des professionnels de santé permettraient de valider la pertinence des réponses dans des contextes réels et d'ajuster le système à des cas d'usage spécifiques.
- Ajout d'un module de raisonnement médical : en combinant l'approche RAG avec des algorithmes de raisonnement, le système pourrait proposer des hypothèses diagnostiques plus complexes et justifiées.

En conclusion, ce projet ouvre la voie à des solutions médicales assistées par l'IA plus fiables, explicables et adaptées aux besoins du terrain, tout en offrant une base solide pour des évolutions futures vers des systèmes d'aide au diagnostic encore plus intelligents et spécialisés

Bibliography

[1] Z. S. Harris, "Distributional Structure," p. 146–162, 1954.

[2] D. Scientyst, "datascientyst," 10 1 2023. [Online]. Available: https://datascientyst.com.

[3] K. S. Jones, "A statistical interpretation of term specificity and its application in retrieval," p. 11–21, 1972.

[4] K. S. Jones, "term frequency–inverse document frequency," 1972. [Online].

[5] T. C. K. C. G. &. D. J. Mikolov, " Efficient Estimation of Word Representations in Vector Space," 2013.

[6] J. S. R. &. M. C. D. Pennington, "Global Vectors for Word Representation.," in *Empirical Methods in Natural Language Processing*, Doha, Qatar, 2014.

[7] T. &. Z. T. Horsmann, "Assigning Fine-grained PoS Tags based on High-precision Coarse-grained Tagging.," in *the 26th International Conference on Computational Linguistics*, Osaka, Japan, 2016.

[8] K. Pakhale, "Comprehensive Overview of Named Entity Recognition," *Models, Domain-Specific Applications and Challenges*, 2023.

[9] A. Lenci, "Understanding Natural Language Understanding Systems: A Critical Analysis," 2023.

[10] A. S. N. P. N. U. J. J. L. G. A. N. .. &. P. I. Vaswani, "Advances in Neural Information Processing Systems," 2017.

[11] J. C. M.-W. L. K. &. T. K. Devlin, "Pre-training of Deep Bidirectional Transformers for Language Understanding," *In Proceedings of NAACL-HLT 2019.*, 2019.

[12] A. N. K. S. T. &. S. I. Radford, "Improving Language Understanding by Generative Pre-Training," 2018.

[13] N. P. N. U. J. Shazeer, "Advances in Neural Information Processing Systems," 2017.

[14] N. Houlsby, "Parameter-Efficient Transfer Learning for NLP," 2019.

[15] N. G. A. J. S. e. a. Houlsby, "Parameter-Efficient Transfer Learning for NLP," 2019.

[16] E. J. S. Y. W. P. e. a. Hu, " Low-Rank Adaptation of Large Language Models," 2021.

[17] B. A.-R. R. &. C. N. Lester, "The Power of Scale for Parameter-Efficient Prompt Tuning," 2021.

[18] X. L. &. L. P. Li, " Prefix-Tuning: Optimizing Continuous Prompts for Generation," 2021.

[19] P. P. E. P. A. P. F. K. Lewis, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *NeurIPS*, 2020.

[20] Chroma, "Chroma is the open-source AI application database," 2023. [Online]. Available: https://www.trychroma.com.

[21] J. D. M. &. J. H. Johnson, "Facebook AI Similarity Search," *Billion-scale similarity search with GPUs,* 2017.

[22] Pinecone, "Pinecone: Managed vector database for machine learning," 2023. [Online]. Available: https://www.pinecone.io.

[23] J. W. C. R. Radford A, "Language models are unsupervised multitask learners," 2019.

[24] M. B. R. N. Brown T, "Advances in neural information processing systems," *Google Scholar,* p. 1, 2020.

[25] H. Touvron, Open and efficient foundation language models, Meta AI, 2023.

[26] M. AI, A Compact Yet Powerful Language Model, announcing-mistral, 2023.

[27] Chowdhery, Scaling language modeling with pathways, 2023.

[28] B. Workshop, open-access multilingual language model, 2022.

[29] S. Black, Large scale autoregressive language modeling with Mesh-TensorFlow, 2021.

[30] B. K. H. F. Moradi M, Gpt-3 models are poor few-shot learners in the biomedical domain, arXiv preprint arXiv, 2021.

[31] P. A. Papanikolaou Y, ata augmented relation extraction with gpt-2, arXiv preprint arXiv, 2020.

[32] Y. S. M. X. T. Q. W. L. a. T.-Y. L. R. Luo, Generative Pre-trained Transformer for Biomedical Text Generation and Mining, Briefings in Bioinformatics, 2022.